Báo cáo kết quả đo các luồng xử lý Wiki

Trích xuất tài liệu • OCR • Embedding • Tìm kiếm • Rerank

Mã phép đo BM-WIKI-20261023
Thời điểm đo khoảng 21:51–21:56 ngày 23/10/2026, múi giờ Asia/Bangkok

Báo cáo ghi nhận kết quả đối chiếu đầu ra với bản chuẩn độc lập dưới cấu hình đang sử dụng. Trong bộ mẫu đã đo, trích xuất hoàn thành 9/9 tệp; OCR hoàn thành 3/4 ảnh; embedding tìm được tài liệu đúng trong top 3 ở 8/8 câu hỏi. Sau bộ lọc rerank hiện tại, tài liệu đúng còn được giữ ở 6/8 câu hỏi.

Cấu hình tại thời điểm đo

Thành phần	Cấu hình
PDF / Excel	pdfplumber / openpyxl
Tiền xử lý PDF	Bỏ header/footer lặp và tăng cường heading đều bật
Chế độ OCR	auto; fallback vision bật; LLM refine tắt
Mô hình OCR	hunyuan-ocr
Embedding	qwen3-embedding-0.6b; 1.024 chiều; task document/query
Reranker	BAAI/bge-reranker-v2-m3
Bộ lọc rerank	Bật; chỉ giữ candidate có điểm > 0,7
LLM / Vision	qwen-3.5-9b / qwen-3.5-9b

Reranker thực tế được lấy từ cấu hình legacy dù active_reranker_model_spec_id trống. Các lượt đo rerank đều sử dụng mô hình, không chuyển sang nhánh dự phòng. Snapshot cấu hình trước/sau các lượt hoàn thành không thay đổi.

Phép đo được thực hiện trong Wiki API image cahy-wiki-backend:upload-scope-261023-cb617a4. Các hàm xử lý được gọi trực tiếp; không tải nguồn QA vào kho, không lập lại chỉ mục và không thay đổi dữ liệu hoặc quyền tài khoản.

1 Trích xuất nội dung tài liệu

Gọi kb_service._extract_text_from_file với cấu hình đang lưu. Bộ mẫu gồm 9 tệp, có văn bản tiếng Việt, mã tài liệu, ngày, số lượng, giá trị tiền và bảng đơn giản. PDF hỗn hợp gồm một trang chữ và một trang ảnh. Bản chuẩn được xây dựng trước khi lấy đầu ra parser/model.

Tệp mẫu	Đơn vị thu được / chuẩn	CER %	WER %	Giá trị đúng / chuẩn	Thời gian giây
vietnamese.txt	1/1	0,00	0,00	3/3	0,12
vietnamese.md	1/1	0,00	0,00	3/3	0,11
vietnamese.docx	1/1	0,00	0,00	2/2	0,29
table.docx	1/1	0,00	0,00	4/4	0,16
table.xlsx	1/1	0,00	0,00	4/4	0,43
slides.pptx	2/2	0,00	0,00	4/4	0,25
digital.pdf	2/2	0,00	0,00	2/2	0,24
scanned.pdf	1/1	0,00	0,00	2/2	4,26
mixed.pdf	2/2	0,00	0,00	2/2	4,13

Kết quả tổng hợp: 9/9 tệp hoàn thành; đủ 12/12 đơn vị nội dung; đúng 26/26 giá trị trọng yếu. Sau chuẩn hóa, có 0 lỗi trên 1.566 ký tự và 0 lỗi trên 314 từ. Trung vị thời gian trích xuất là 0,25 giây/tệp; PDF scan và PDF hỗn hợp lần lượt cần 4,26 và 4,13 giây.

Cách chấm nội dung

CER là số thao tác sửa ký tự tối thiểu chia cho số ký tự bản chuẩn. WER tính tương tự ở mức từ, tách từ theo khoảng trắng. Tỷ lệ gộp được tính từ tổng lỗi chia tổng độ dài bản chuẩn, không lấy trung bình phần trăm từng tệp.

Văn bản được chuẩn hóa Unicode NFC và khoảng trắng; loại markup Markdown, tiền tố slide và sheet do parser sinh ra. Dấu tiếng Việt, hoa/thường, số và dấu câu được giữ khi chấm. Giá trị trọng yếu được kiểm tra theo chuỗi khớp chính xác có ranh giới từ.

Đơn vị nội dung là trang PDF, slide PPTX, sheet XLSX hoặc khối văn bản, tùy định dạng. Đủ số đơn vị không đồng nghĩa khôi phục đúng bố cục trang in. Bộ đo này chưa chấm bảng phức tạp, hình ảnh hoặc định dạng trình bày.

2 Nhận dạng ký tự OCR

Gọi trực tiếp luồng OCR với hunyuan-ocr và prompt đang lưu. Bộ đo gồm một ảnh rõ, bản nghiêng 2°, bản mờ Gaussian sigma 0,8 và một ảnh trắng. Ba ảnh có chữ dùng cùng bản chuẩn 148 ký tự, 27 từ và 5 giá trị trọng yếu mỗi ảnh.

Điều kiện ảnh	Trạng thái	CER %	WER %	Giá trị đúng / chuẩn	Thời gian giây
Ảnh rõ	Hoàn thành	0,000	0,000	5/5	4,43
Nghiêng 2°	Hoàn thành	1,351	7,407	5/5	4,64
Mờ sigma 0,8	Hoàn thành	2,027	7,407	4/5	3,98
Ảnh trắng	Vượt 100 giây	Không chấm	Không chấm	Không chấm	106,69

Kết quả trên các đầu ra nhận được

Ba ảnh có chữ hoàn thành trong khoảng 3,98–4,64 giây, trung vị 4,43 giây. Tổng cộng có 5 lỗi ký tự trên 444 ký tự, tương ứng CER 1,13%; 4 lỗi từ trên 81 từ, tương ứng WER 4,94%. Số giá trị trọng yếu khớp chính xác là 14/15.

Điều kiện	Sai khác quan sát
Ảnh nghiêng	2 thao tác sửa ký tự và 2 thao tác sửa từ sau chuẩn hóa; output có thay đổi hoa/thường hoặc dấu câu.
Ảnh mờ	“GIẢ” thành “GIÁ”; “1.250.000” thành “1,250,000”. Tổng 3 thao tác sửa ký tự và 2 thao tác sửa từ.

Dấu phân cách số tiền bị đổi nên ca ảnh mờ không đạt đối chiếu chuỗi tiền chính xác. Phép đo ghi nhận thay đổi biểu diễn; chưa kết luận giá trị tiền đã bị diễn giải thành một số tiền khác.

Ghi nhận riêng đối với ảnh trắng

Ca ảnh trắng không trả đầu ra trong giới hạn kiểm tra 100 giây và bị dừng bởi bộ đo. Tổng thời gian quan sát có cả khởi động/thu kết quả là 106,69 giây. Tỷ lệ hoàn thành toàn bộ nhóm OCR là 3/4, tương ứng 75%.

Ca này không được tính là nhận dạng đúng văn bản rỗng và không đưa vào mẫu số CER/WER. Giới hạn kiểm tra ngắn hơn tổng timeout/retry có thể có của SDK vận hành, nên chưa xác định kết quả nếu chờ lâu hơn. Chưa đo ingest PDF trắng.

3 Embedding và xếp hạng lại kết quả

Bộ tham chiếu gồm 8 đoạn độc lập và 8 câu hỏi, mỗi câu gán trước đúng một tài liệu liên quan. Embedding được tính bằng mô hình đang cấu hình, so cosine trong bộ nhớ. Rerank dùng cùng 8 candidate/câu theo thứ tự embedding; một lượt bổ sung ghi điểm thô trước lọc.

Phương án	Đúng top 1	Đúng top 3	MRR	nDCG@3
Embedding cosine	7/8	8/8	0,9375	0,9539
Rerank trước lọc	8/8	8/8	1,0000	1,0000
Rerank với điểm > 0,7	6/8	6/8	0,7500	0,7500

Nội dung câu hỏi	Hạng ban đầu	Điểm rerank tài liệu đúng	Hạng sau lọc 0,7
Kiểm kê máy quét	1	0,995871	1
Thời hạn gửi đơn nghỉ	1	0,870565	1
Thông tin ghi sổ khách	1	0,808576	1
Kiểm tra khôi phục backup	1	0,031803	Bị loại
Máy nhiễm mã độc không dấu	2	0,000990	Bị loại
Thời gian và nơi họp	1	0,862904	1
Thiết bị mang đi tập huấn	1	0,853022	1
Tiêu chí lập danh mục hồ sơ	1	0,852548	1

Hai tài liệu đúng bị loại đều đứng đầu khi xét điểm rerank thô. Điểm quan sát lần lượt là 0,031803 và 0,000990, thấp hơn ngưỡng 0,7. Các lượt đo đều ghi nhận mode rerank; kết quả này không xuất phát từ nhánh dự phòng.

Đối chiếu ngưỡng trên cùng bộ điểm thô

Ngưỡng giữ điểm	Tài liệu đúng còn giữ	Tổng candidate giữ
Không lọc	8/8	64
> 0,001	7/8	10
> 0,01 hoặc > 0,03	7/8	7
> 0,3; 0,5; 0,6; 0,7; 0,8	6/8	6

Các ngưỡng đối chiếu chỉ được áp dụng trong bộ nhớ, không thay đổi setting. Top k là tỷ lệ câu có tài liệu đúng trong k vị trí đầu. MRR là trung bình nghịch đảo hạng; nDCG@3 dùng một tài liệu liên quan/câu. Tài liệu bị lọc mất được tính 0. Điểm thô chưa được coi là xác suất chính xác đã hiệu chuẩn.

4 Tìm kiếm trên chỉ mục đang vận hành

Gọi wiki_search_service.search trong transaction READ ONLY, lọc scope global, giới hạn 10 kết quả/câu. Chỉ mục có 418 trang global tại thời điểm đo. Bảy trang mục tiêu được chọn theo ID trước truy vấn; bổ sung một mã không tồn tại làm ca đối chứng âm.

Truy vấn	Hạng mục tiêu	Số trả	Số candidate	Giây
Điều 2 giải thích từ ngữ Luật 55/2024/QH15	1	9	51	5,80
Điều 39 Luật 55/2024/QH15 phòng cháy chữa cháy tình nguyện	1	10	72	2,94
Điều 19 Nghị định 136/2020/NĐ-CP phương án chữa cháy	1	10	52	2,72
Kiến thức, kỹ năng về chữa cháy	1	10	39	3,03
tinh huong tai nan giao thong	1	2	32	3,07
nhiệm vụ chữa cháy	1	10	51	4,08
Kiến thức, kỹ năng về thoát nạn, cứu nạn, cứu hộ	1	10	37	3,39
KT-XYZ-NONEXISTENT-261023-QA	Không có	0	15	1,41

Cả 7 trang mục tiêu đều xuất hiện ở hạng 1. Mã không tồn tại trả 0 kết quả. Metadata của cả 8 lượt là hybrid + rerank, không chuyển sang nhánh dự phòng; số candidate trước lọc nằm trong khoảng 15–72.

Phạm vi diễn giải số liệu

Các ca trên chủ yếu tra theo Điều, số văn bản hoặc tiêu đề, có một câu không dấu. Mỗi câu chỉ có một trang mục tiêu đã định trước; chưa gán nhãn đầy đủ mức liên quan của các kết quả còn lại. Vì vậy không suy ra Precision toàn kho hoặc độ chính xác cho mọi câu hỏi nghiệp vụ.

Đây là phép đo service/index trực tiếp, không kiểm thử API xác thực, SSO hoặc phân quyền. Chưa đo câu trả lời cuối của chat agent, trích dẫn, hiệu lực văn bản pháp luật, xuất/tải file, độ phủ lịch sử, file 200 MB, DOC/XLS cũ hoặc scan vận hành đại diện. Các bộ mẫu nhỏ dùng xác định hành vi quan sát được, không phải chứng nhận độ chính xác toàn hệ thống.

Hồ sơ số liệu đối chiếu

Bản chuẩn và hash tệp nằm trong manifest.json; đầu ra thô được lưu theo từng ca. reviewed-results.json chứa kết quả chấm; text-cases.csv, embedding-cases.csv, rerank-cases.csv, threshold-cases.csv và live-search-cases.csv chứa các bảng số liệu. Điểm thô được lưu trong rerank-raw-score-audit.json. Cấu hình được lưu sau khi loại bỏ key/token.

Các số phần trăm và thời gian trong báo cáo đã làm tròn để trình bày; số liệu gốc được giữ trong hồ sơ đo. Không có ngưỡng nghiệm thu tổng thể được áp dụng và không cộng gộp các tầng thành một điểm chính xác chung.